

Demo day – Curso de Machine Learning

Equipe 3

Classificação de Resíduos Recicláveis





Equipe

Equipe 3

- **Nicole Souza**
- **João Pedro Martins**
- **Moema Rocha**
- **Gustavo Nunes**
- **Caio Lima**
- **Carla Adriana**
- **Giovanna Gurgel**
- **Anderson Ricardo**
- **Fernando Torres**

Sumário

- Introdução
- Metodologia
- Resultados
- Conclusões





Introdução

Introdução

- **Resumo do Problema**

O problema abordado pelo dataset de "**Recyclable and Household Waste Classification**" é a necessidade de classificar resíduos corretamente para melhorar os processos de reciclagem e gerenciamento de resíduos. Isso é fundamental para reduzir o impacto ambiental causado pelo descarte incorreto e aumentar a eficiência na triagem automatizada em centrais de reciclagem.



Introdução

- **Motivos do Problema**


1. **Crescimento no Volume de Resíduos:** O aumento da população e do consumo gera uma grande quantidade de resíduos que requerem gerenciamento eficaz;

2. **Baixa Taxa de Reciclagem:** Muitas regiões apresentam dificuldades em separar materiais recicláveis devido à dependência de processos manuais;

3. **Impacto Ambiental:** O descarte inadequado de resíduos contribui para a poluição do solo, da água e do ar;

4. **Necessidade de Automação:** Soluções automatizadas, como modelos de aprendizado de máquina, podem melhorar significativamente a precisão e a velocidade na classificação, substituindo ou complementando o trabalho humano.

Introdução



- **Objetivo Geral**

Desenvolver um modelo eficiente de **aprendizado de máquina**, baseado em redes neurais convolucionais (como a ResNet50), para realizar a classificação automática de resíduos recicláveis e domésticos, auxiliando na triagem correta de materiais. Isso contribui para:

Aumentar a eficiência na reciclagem: Melhorando a separação de resíduos recicláveis de materiais orgânicos ou não recicláveis.

Reduzir impactos ambientais: Diminuindo o descarte inadequado e promovendo práticas sustentáveis.

Automatizar processos industriais: Substituindo ou complementando a triagem manual, especialmente em sistemas de gerenciamento de resíduos.



Metodologia

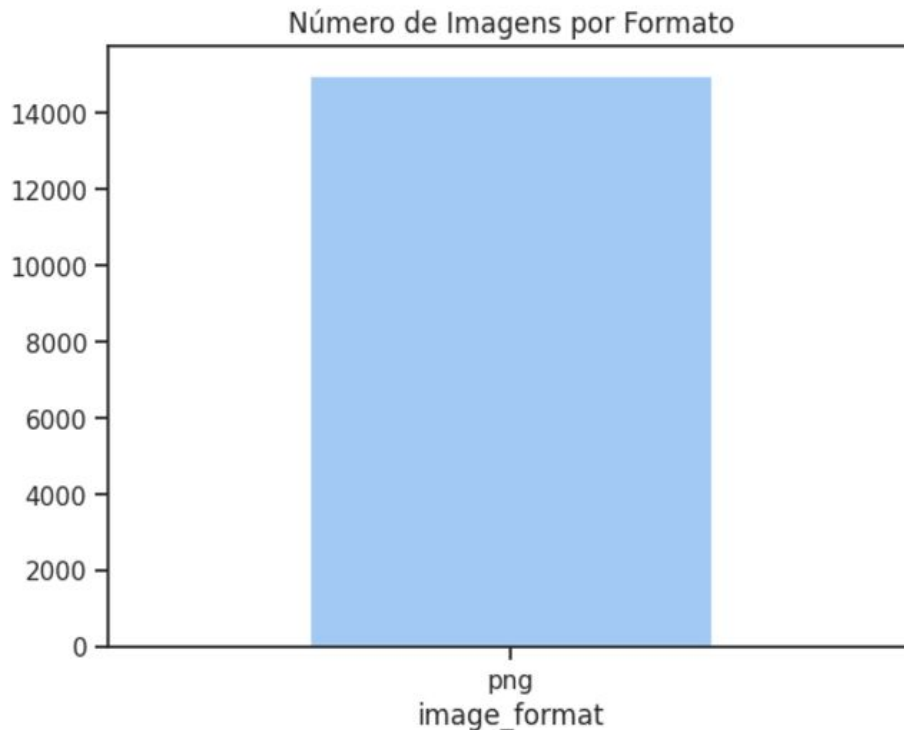
Metodologia

- **Base de dados**

O dataset contém uma coleção abrangente de **15.000 imagens** de alta qualidade, distribuídas em **30 categorias distintas, cada uma contendo 500 imagens**.

Todas as imagens estão no **formato PNG**, garantindo alta qualidade e compatibilidade com bibliotecas de aprendizado de máquina.

O dataset não possui imagens corrompidas.



Metodologia

- **Base de dados**

Recyclable and Household Waste Classification

A pasta principal "imagens" contém subpastas que representam categorias de resíduos, sendo seus nomes utilizados como rótulos.

Cada subpasta possui duas categorias:

Default: Imagens de estúdio (250 por subpasta) com representações claras e controladas dos itens.

Real World: Imagens em ambientes reais (250 por subpasta) capturando cenários como latas de lixo ou chão desorganizado.

Metodologia

- **Base de dados**

30 Categorias

- | | |
|-------------------------------|-------------------------------|
| 1. aerosol_cans | 16. office_paper |
| 2. aluminum_food_cans | 17. paper_cups |
| 3. aluminum_soda_cans | 18. plastic_cup_lids |
| 4. cardboard_boxes | 19. plastic_detergent_bottles |
| 5. cardboard_packaging | 20. plastic_food_containers |
| 6. clothing | 21. plastic_shopping_bags |
| 7. coffee_grounds | 22. plastic_soda_bottles |
| 8. disposable_plastic_cutlery | 23. plastic_straws |
| 9. eggshells | 24. plastic_trash_bags |
| 10. food_waste | 25. plastic_water_bottles |
| 11. glass_beverage_bottles | 26. shoes |
| 12. glass_cosmetic_containers | 27. steel_food_cans |
| 13. glass_food_jars | 28. styrofoam_cups |
| 14. magazines | 29. styrofoam_food_containers |
| 15. newspaper | 30. tea_bags |

styrofoam_food_containers plastic_cup_lids plastic_water_bottles plastic_trash_bags glass_beverage_bottles glass_beverage_bottles plastic_shopping_bags plastic_food_containers



eggshells magazines disposable_plastic_cutlery cosmetic_containers plastic_food_containers clothing plastic_shopping_bags styrofoam_cups



cardboard_packaging aluminum_soda_glass_beverage_bottles newspaper plastic_detergent_plastic_food_containers plastic_straws styrofoam_food_containers



glass_food_jar plastic_shopping_bags plastic_detergent_bottles shoes styrofoam_food_containers aluminum_food_cans plastic_water_bottles newspaper



coffee_grounds clothing coffee_grounds styrofoam_cup plastic_water_bottles plastic_shopping_bags eggshells cardboard_packaging



clothing plastic_cup_lids shoes eggshells glass_beverage_bottles plastic_trash_bags styrofoam_cups cardboard_packaging




clothing eggshells disposable_plastic_cutlery magazines coffee_grounds newspaper paper_cups plastic_trash_bags



steel_food_cans magazines disposable_plastic_cutlery aerosol_cans eggshells tea_bags plastic_trash_bags coffee_grounds





Metodologia

- Métodos de Processamento

Imagens Originais ->



Metodologia

- **Métodos de Processamento**
(Exemplos de Data Augmentation)

RandomFlip ->




Metodologia

- **Métodos de Processamento**
(Exemplos de Data Augmentation)

RandomCropAndResize ->

Esta operação seleciona um subconjunto aleatório da imagem e, em seguida, redimensiona-o para o tamanho alvo fornecido. Ao usar esse aumento, forçamos nosso classificador a se tornar espacialmente invariante. Além disso, esta camada aceita um `aspecto_ratio_factor` que pode ser usado para distorcer a proporção da imagem.




Metodologia

- **Métodos de Processamento**
(Exemplos de Data Augmentation)

RandomCutOut ->

Esta técnica de aumento corta aleatoriamente retângulos de imagens e os preenche.




Metodologia

- **Métodos de Processamento**
(Exemplos de Data Augmentation)

CutMix ->

Em vez de substituir as áreas recortadas por ruído aleatório, o CutMix substitui essas regiões por regiões de outras imagens amostradas dentro do seu conjunto de treinamento! Após esta substituição, o rótulo de classificação da imagem é atualizado para ser uma mistura do rótulo de classe da imagem original e mista.




Metodologia

- **Métodos de Processamento**
(Exemplos de Data Augmentation)

MixUp ->

MixUp() funciona amostrando duas imagens de um lote e, em seguida, mistura literalmente suas intensidades de pixel, bem como seus rótulos de classificação.






Resultados

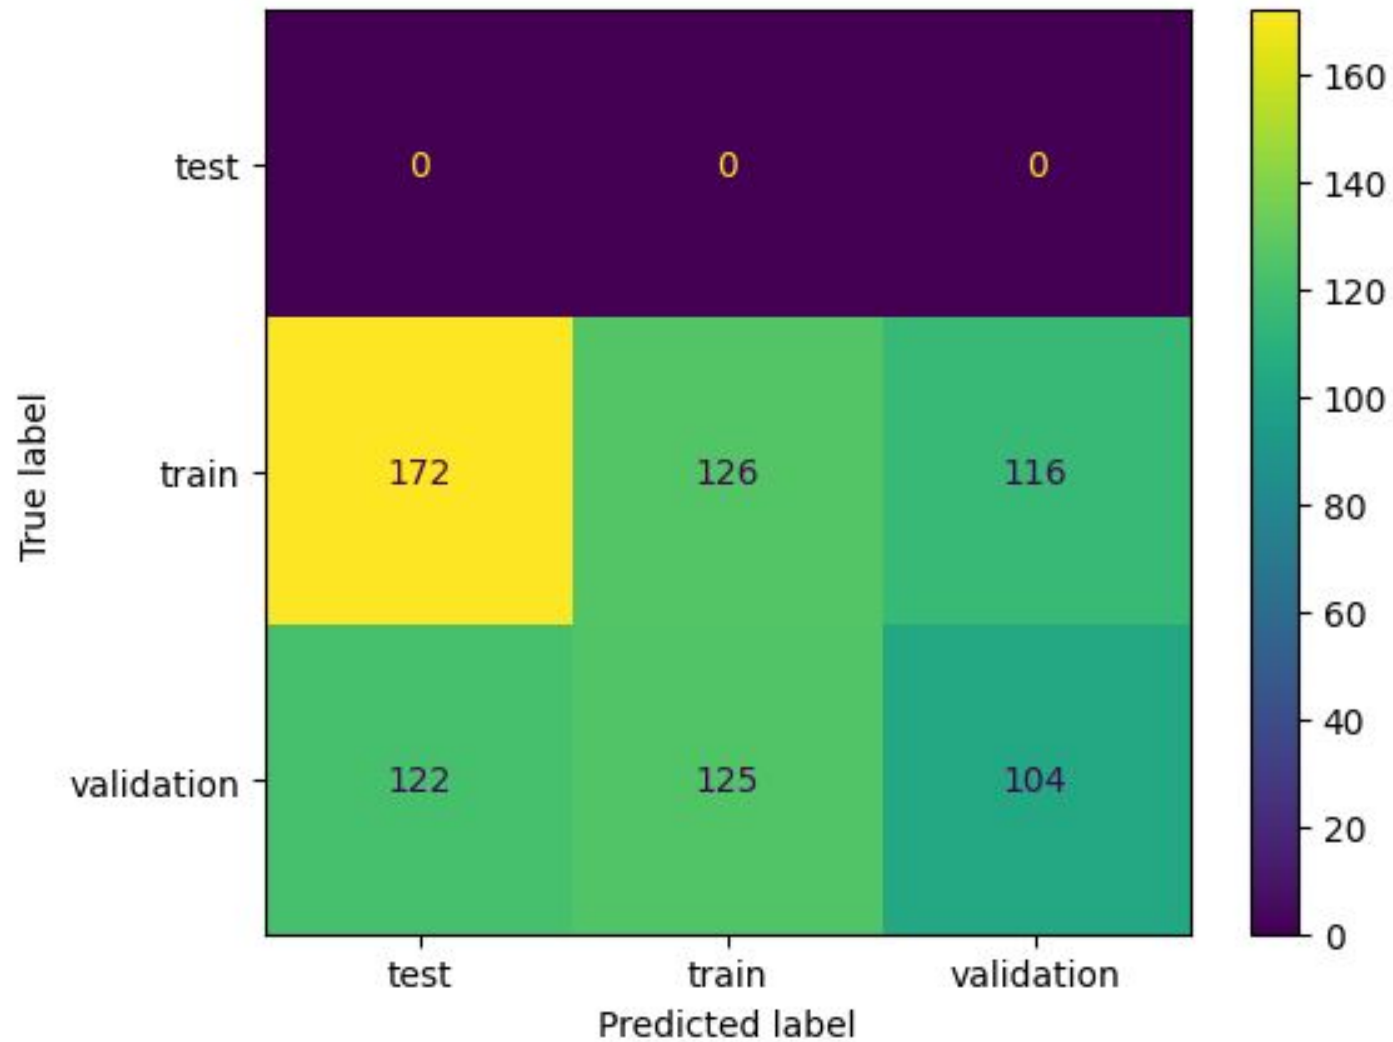
1º Treinamento com 1 Épocas

Ajustes:

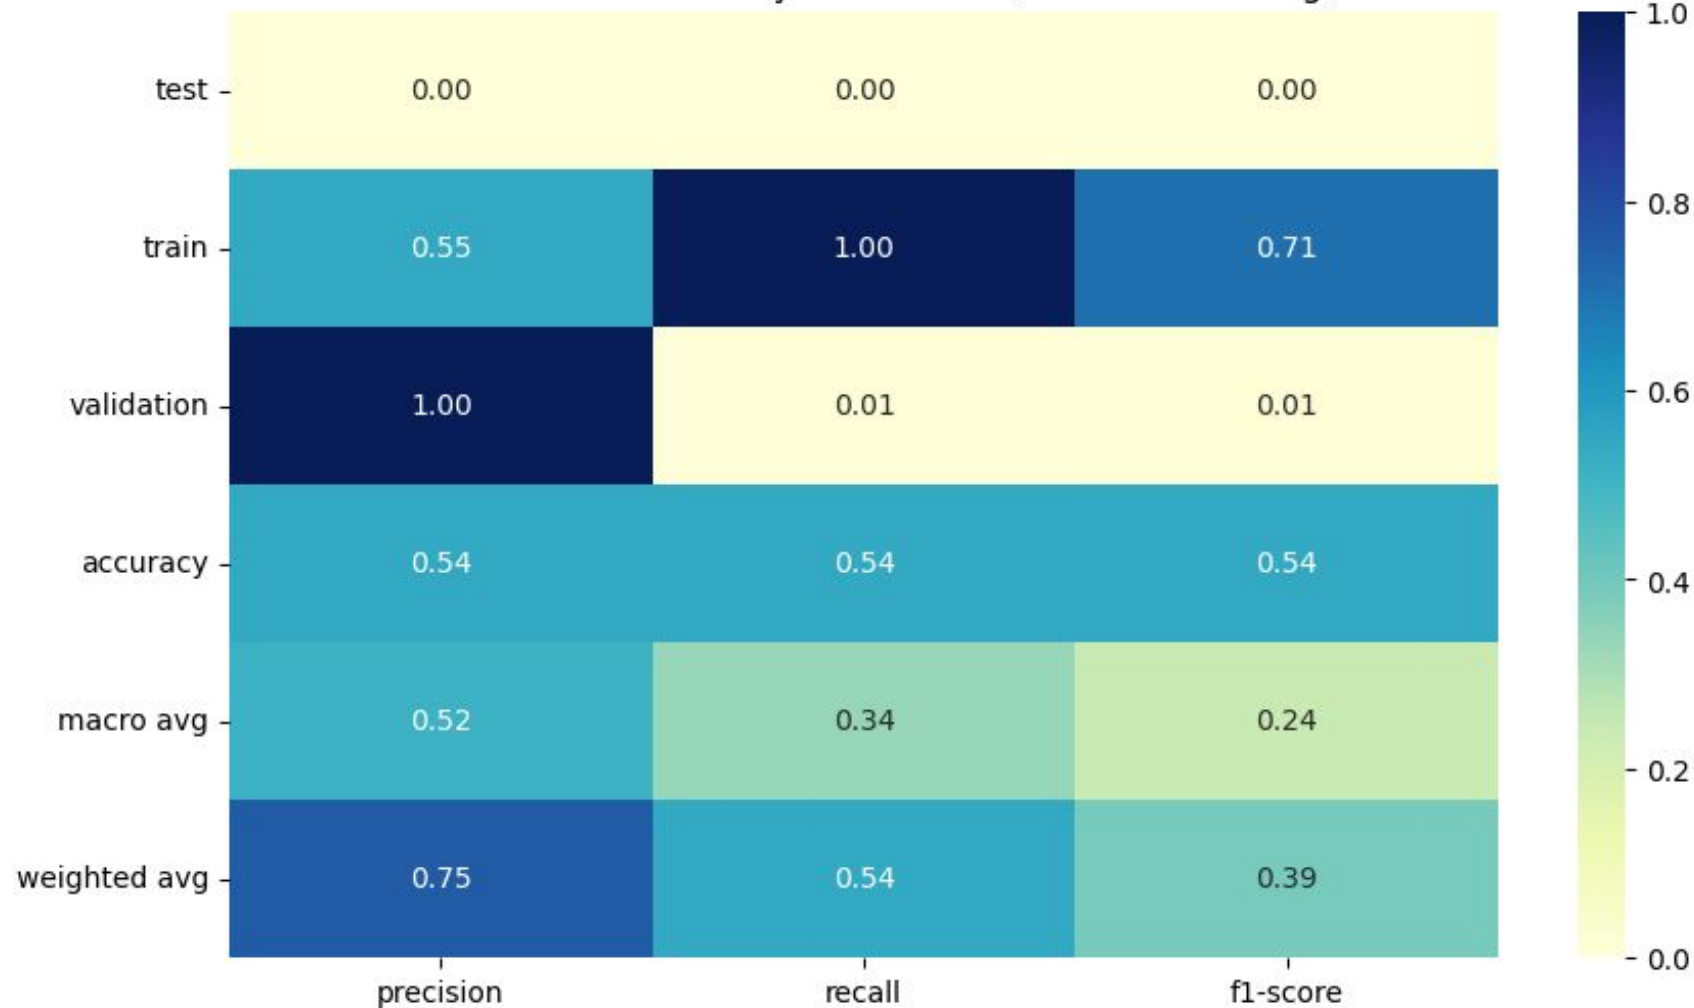
- Redução do BATCH_SIZE: 64
- Métricas utilizadas na compilação do modelo: `metrics=['accuracy']`
- Data Augmentation: Aumento dos dados
 - Melhora da generalização mitigando o overfitting
 - Aumento da robustez
 - Equilibrar o dataset (Desbalanceados)
 - Prevenção de memorização

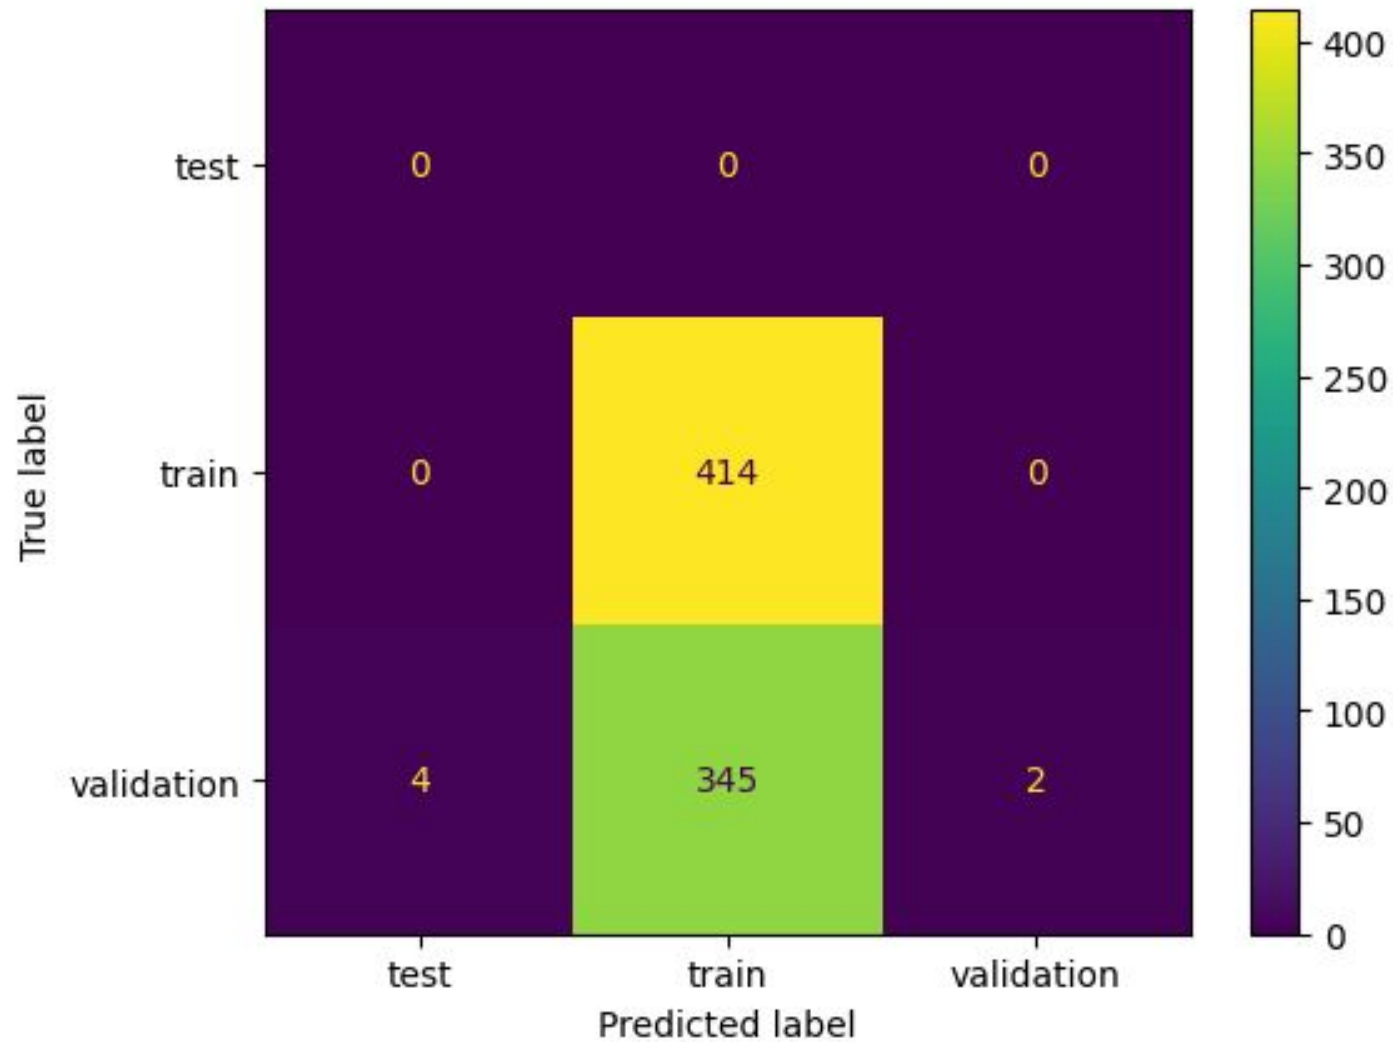
Resultados





Relatório de Classificação ResNet50 (Transfer Learning)






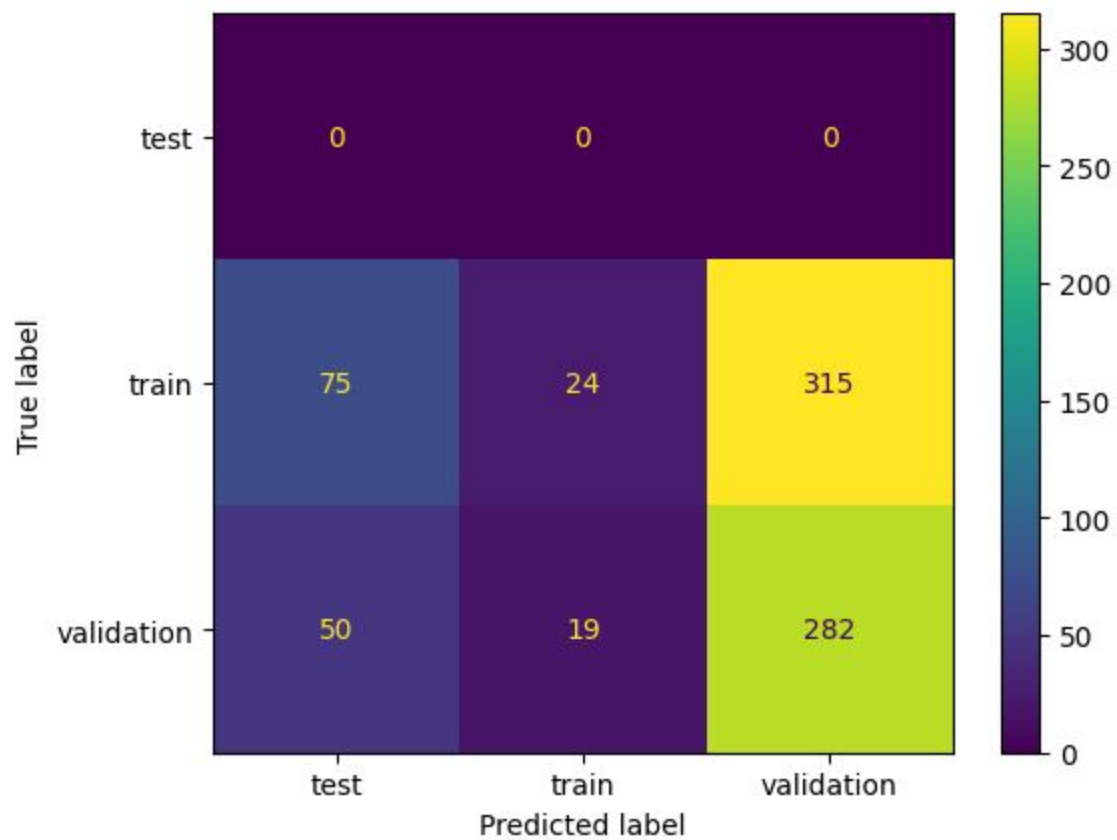
2º Treinamento com 2 Épocas e ajustes de hiper parametros

Ajustes:


- Redução do BATCH_SIZE: 16
- Regularização L2 adicionada: `kernel_regularizer=tf.keras.regularizers.l2(0.001)`
- Adicionado mais métricas na compilação do modelo: `metrics=['accuracy', 'precision', 'recall', 'f1_score']`
- Data Augmentation: Aumento dos dados


Relatório de Classificação ResNet50





Relatório de Classificação ResNet50 (Transfer Learning)







Conclusões

Conclusões

- **Modelo ResNet50**
 - alcançou uma acurácia de apenas 0.3673 no conjunto de validação
- **Abordagem de transfer learning, utilizando as camadas pré-treinadas do ResNet50**
 - resultou em uma acurácia consideravelmente superior, atingindo 0.5359
- **Demonstra a eficácia do transfer learning em extrair informações úteis de um modelo pré-treinado**
- **Acurácia ainda é relativamente baixa, sugerindo a necessidade de investigações adicionais para otimizar o modelo**

Conclusões

- **Possíveis fatores a serem considerados:**
 - tamanho do conjunto de dados
 - balanceamento das classes
 - qualidade das imagens
 - necessidade de mais treinamento ou técnicas de regularização para mitigar o overfitting
- Aumentar o tamanho do dataset
- Melhorar a qualidade das imagens
- Balanceamento das classes
- Ajustar os hiperparâmetros
- Aumentar o data augmentation
- Explorar outras arquiteturas
- Técnicas de regularização
- Análise detalhada dos erros

Referências

1. ZHANG, Q. et al. Waste image classification based on transfer learning and convolutional neural network. *ScienceDirect*, [S.l.], v. 262, n. 2, p. 1160–1174, 2022. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0956053X21004815>. Acesso em: 27 out. 2024.
2. DUAN, Y.; ZHENG, D.; WANG, R.; TAN, T.; PANG, P. C. Focus-RCNet: a lightweight recyclable waste classification algorithm based on focus and knowledge distillation. *ResearchGate*, [S.l.], 2024. Disponível em: https://www.researchgate.net/publication/375417850_Focus-3RCNet_a_lightweight_recyclable_waste_classification_algorithm_based_on_focus_and_knowledge_distillation. Acesso em: 11 nov. 2024.
3. MA, X.; LI, Z.; ZHANG, L. An improved ResNet-50 for garbage image classification. *Hrcak*, [S.l.], 2023. Disponível em: <https://hrcak.srce.hr/file/408378>. Acesso em: 11 nov. 2024.

Referências

1. LI, K. Analysis and suggestions on classification and recycling of urban domestic waste. *IOP Science*, [S.l.], v. 647, n. 1, 2023. Disponível em:
<https://iopscience.iop.org/article/10.1088/1755-1315/647/1/012177/pdf>. Acesso em: 27 out. 2024.
2. AL-MAHMUD, S.; PRATA, M.; KING, A. Recyclable and household waste classification. *Kaggle*, [S.l.], 2023. Disponível em:
<https://www.kaggle.com/datasets/alistairking/recyclable-and-household-waste-classification>. Acesso em: 27 out. 2024.



Obrigado!



 (85) 99115-1117

 www.instagram.com/avanti.ia/

 www.linkedin.com/company/avantiatlantico

www.atlanticoavanti.com.br